

MASTER DONNÉES, APPRENTISSAGE ET
CONNAISSANCES-DAC

RAPPORT PROJET DAC

CLUSTERING POUR LES
INFRASTRUCTURES SANS FILS

REALISÉ PAR :

HANANE DJEDDAL
LITICIA TOUZARI

ENCADRÉ PAR :

ANASTASIOS GIOVANIDIS

Résumé

L'augmentation croissante du trafic de données a posé de grands défis aux opérateurs mobiles pour augmenter leur capacité de traitement des données, ce qui entraîne une consommation d'énergie et des coûts de déploiement importants sans avoir nécessairement une croissance dans le chiffre d'affaires vu que l'utilisateur attend qu'il paye moins pour plus de données. Avec l'émergence de l'architecture Cloud Radio Access Network (C-RAN) les unités de traitement des données peuvent désormais être centralisées et partagées entre les stations de base, chose qui réduit les coûts de déploiement et offre une architecture de base qui facilite l'implémentation des algorithmes et des solutions pour des problèmes divers. Le partage des unités de traitement se fait en clusterisant les stations de base et en mappant chaque cluster à une unité de traitement de données. Les schémas de trafic des stations de base étant très dynamiques à différents moments et endroits, par exemple le trafic dans une région résidentielle durant la journée n'est pas le même durant la nuit, L'idée est de créer des cluster de stations de base avec des schéma de trafic complémentaires afin que l'unité de traitement peut être pleinement utilisée à différentes périodes de temps, et la capacité requise à déployer devrait être inférieure à la somme des capacités d'une seule base stations. Cependant, il est difficile de prévoir et de caractériser les schémas de trafic à l'avance pour réaliser des schémas de regroupement optimaux. Dans ce rapport, nous abordons ces problèmes en étudiant les solutions déjà proposées dans le cadre d'optimisation C-RAN basé sur l'apprentissage en profondeur. Premièrement, nous implémentons les algorithmes déjà existants, nous procédons par la suite à évaluer leur performances en utilisant des dataset fournis par Orange. Nous exposons aussi des différents algorithmes de clustering, principalement K-means, et nous essayons à les adapter à notre problème. Nous terminons par comparer les performances des différentes méthodes.

Mots clés: C-RAN, RAN Cloudification, Clustering, K-means

Introduction

Aujourd’hui, le trafic de données sur les réseaux mobiles connaît une croissance explosive à mesure que les smartphones et tablettes compatibles avec Internet deviennent de plus en plus populaires.

Afin de répondre à la demande croissante de trafic de données, les opérateurs de réseaux mobiles doivent augmenter leur capacité de traitement de données, comme le déploiement de plus de stations de base et l’ajout d’unités de traitement de données supplémentaires aux stations de base.

Cependant, les dépenses en capital liées au déploiement de ces infrastructures de réseau deviennent de plus en plus élevées. Par conséquent, l’optimisation des dépenses d’investissement et des dépenses d’exploitation tout en maintenant une qualité de service est devenue une nécessité pour les opérateurs de réseaux mobiles.

Ce projet vise à mettre en œuvre des techniques de clustering afin de regrouper les ressources et infrastructures radio dans le but d’améliorer l’efficacité des services. Chaque ville est desservie par plusieurs nœuds sans fil qui sont géographiquement séparés; chacun d’eux est responsable d’une charge différente des appels vocaux, de la consommation multimédia et des messages provenant de différentes zones de la ville dans la journée. A ce jour, les différents nœuds d’accès du réseau ne coopèrent pas, et chaque nœud est plutôt responsable de sa propre zone géographique. Les architectures futures des réseaux proposent de regrouper plusieurs stations sans fil et les traiter comme un ensemble avec un contrôleur commun, afin que les stations surchargées puissent être soutenues par des stations sous-chargées.

Dans le cadre de ce projet, on proposera des méthodes de clustering efficaces, adaptées aux spécificités de l’environnement sans fil et des métriques des services de télécommunication. On utilisera des données fournies par l’opérateur Orange.

Contents

1	État de l'art	4
1.1	L'architecture D-RAN	4
1.2	L'architecture C-RAN	5
1.3	Méthodes de Clustering	6
1.3.1	K-means Clustering	7
1.3.2	Clustering Hierarchique	9
1.4	L'algorithme DCCA	10
1.4.1	Définitions	11
2	Conception	14
2.1	Analyse des données	14
2.1.1	Données Géographiques	14
2.1.2	Données de Trafic	15
2.2	Application des algorithmes	16
2.2.1	Clustering sur les Données géographique	18
2.2.2	Clustering sur les Données du trafic	18

1. État de l'art

Dans cette partie, on va introduire les technologies et concepts principaux dans le projet. D'un part, on parle de l'architecture traditionnelle des réseaux sans fils et son évolution à l'architecture C-RAN. D'autre part, on présente deux méthodes de clustering: K-means et le clustering héirarchique dans leur version la plus générale. À la fin, on introduit la methode de clustering proposée dans l'artcile [3] qu'on va implémenter et evaluer dans la suite du rapport.

1.1 L'architecture D-RAN

Dans l'architecture traditionnelle Distributed Radio Access Network (D-RAN), le site de chaque cellule (eNodeB) contient deux compnants: une unité de traitement de bande de base (BBU) au pied de la tour et une tête radio à distance (Remote Radio Head, RRH) au sommet. Les deux composants sont reliés par un câble en fibre optique. Le RRH s'occupe des fonctionnalités radio telles que conversion des fréquences, amplifications, A/D et D/A conversion etc. Quant à la BBU, elle effectue les traitements de la bande de base, des packets, etc et assure le fonctionnement de la station.




Figure 1.1: D-RAN

Une solution pour accomoder le nouveau volume du trafic est de deployer plus de cellules de petite taille et reutiliser les fréquences. Cependant, cette approche necessite des coûts imporants d'installation et crée un problème d'interférence entre les cellules.

Un autre problème que engendre cette architecture est la consomation d'énergie. En effet, les stations de base consomme le plus d'énergie dans les réseaux sans fils et augmenter le nombre de cellules c'est augmenter les coûts d'exploitation et l'émission du gaz carbonique, qui, bien évidemment, a un effet négative sur l'environnement.

Une nouvelle architecture doit être capable d'offrir une solution à ces problèmes tout en garadant un revenue positif.

1.2 L'architecture C-RAN

L'architecture Cloud Radio Access Network (C-RAN) est un concept qui combine des technique de Centralisation, Collaboration et de Virtulaisation pour offrir une performance aémlioré avec moins de coûts et moins de consomation d'énergie (Clean RAN).

L'idée de C-RAN est de centraliser les différentes ressources de traitement de bande de base (les BBUs) pour créer un 'pool' qui gère dynamiquement l'allocation de ressources. Les composants de base dans une architecture C-RAN sont :

1. BBU pool : regroupe l'ensemble BBUs dans un centre et permet l'allocation dynamique et le reconfiguration basée sur des données en temps-réel.
2. RRH : Comme dans les architectures traditionnelle, les RRHs sont distribués dans les différentes station de base et assurent les mêmes fonctionnalités de couvrage des signaux.
3. Réseau de transmission : une interconnexion entre une instance de BBU et un RRH.

Ce concept, simple et direct, offre plusieurs avantages. La centralisation des BBUs dans un seul pool avec des interconnexions qui relient les différents noeuds




Figure 1.2: C-RAN

avec une bande passante élevée et une faible latence, permet la communication et l'échange d'information et par conséquent plusieurs technologies telles que Joint Processing et cooperative multiPoint (CoMP), difficile à implémenter dans l'architecture traditionnelle, seront facilement intégrées. En plus, contrairement à l'architecture traditionnelle où les ressources d'une BBU sont limitées à la station de base où elle est installée, dans le contexte C-RAN, les ressources sont agrégées dans un pool (ressources cloudification) et peuvent être allouées sur demande, ce qui réduit la consommation d'énergie et optimise l'utilisation des ressources. Aussi, due à sa nature basée sur le concept de Cloud et centralisation, C-RAN est caractérisée par sa flexibilité et scalabilité qui sont nécessaires pour l'évolution des systèmes 5G.

1.3 Méthodes de Clustering

Le clustering fait référence à un ensemble très large de techniques pour rechercher des sous-groupes, ou clusters, dans un ensemble de données. Lorsque nous regroupons les observations d'un ensemble de données, nous cherchons à les diviser en groupes distincts afin que les observations au sein de chaque groupe soient assez similaires les unes aux autres, tandis que les observations dans différents groupes sont assez différentes les unes des autres. Bien sûr, pour concrétiser cela, nous devons définir ce que signifie que deux ou plusieurs observations soient similaires ou différentes. En effet, il s'agit souvent d'une considération spécifique au domaine qui doit être faite sur la base de la connaissance des données étudiées. Le clustering étant populaire dans de nombreux domaines, il existe un grand nombre de méthodes de clustering. Nous nous concentrons sur les deux approches de clustering les plus connues: le clustering K-means et le clustering hiérarchique. Dans le clustering K-means, nous cherchons à

partitionner les observations en un nombre prédéfini de clusters. En revanche, dans le clustering hiérarchique, le nombre de clusters n'est pas prédéfini, nous nous retrouvons avec une représentation visuelle arborescente des observations, appelée dendrogramme, qui permet de visualiser immédiatement les regroupements obtenus pour chaque nombre possible de regroupements, de 1 à n . En général, nous pouvons regrouper des observations sur la base des caractéristiques afin d'identifier des sous-groupes parmi les observations, ou nous pouvons regrouper des caractéristiques sur la base des observations afin de découvrir des sous-groupes parmi les caractéristiques. [3]

1.3.1 K-means Clustering

Le clustering K-means est une approche simple et élégante pour partitionner un ensemble de données en K clusters distincts qui ne se chevauchent pas. Pour effectuer le clustering K-means, nous devons d'abord spécifier le nombre souhaité de clusters K ; alors l'algorithme K-means assignera chaque observation à exactement l'un des K clusters. La figure ci-dessous montre les résultats obtenus en déroulant l'algorithme sur l'ensemble des RRHs de Lille (ville Française) avec 88 emplacement différents.




Figure 1.3: K-means clustering

La procédure de clustering K-means résulte d'un problème mathématique simple et intuitif. Nous commençons par définir une notation. Soit C_1, \dots, C_K désignent des ensembles contenant les indices des observations dans chaque cluster. Ces ensembles satisfont deux propriétés:

1. $C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}$ chaque observation appartient à au moins

l'un des K clusters.

2. $C_k \cap C_{k'} = \emptyset$ aucune observation n'appartient à plus d'un cluster.

Par exemple, si la i ème observation se trouve dans le k ème groupe, alors $i \in C_k$. L'idée derrière le clustering K-means est qu'un bon clustering est celui pour lequel la variation intra-cluster est aussi petite que possible. La variation intra-cluster pour le cluster C_k est une mesure $W(C_k)$ de la différence entre les observations au sein d'un cluster. Par conséquent, nous voulons résoudre le problème : $\min_{C_1, C_2, \dots, C_K} \sum_{k=1}^K W(C_k)$. [3]

En termes, cette formule dit que nous voulons partitionner les observations en K clusters de telle sorte que la variation totale intra-cluster, additionnée sur tous les K clusters, soit aussi petite que possible.

Il s'agit en fait d'un problème très difficile à résoudre avec précision, car il existe presque K^n façons de partitionner n observations en K clusters. Néanmoins, il existe un algorithme très simple pour fournir un optimum local - une assez bonne solution - au problème d'optimisation K-means. Cette approche est présentée dans le pseudo l'algorithme suivant :

Algorithme K-means Clustering

1. Attribuez au hasard un numéro, de 1 à K , à chacune des observations. Celles-ci servent d'initialisations.
2. Itérez jusqu'à ce que les affectations de cluster cessent de changer:
 - (a) Pour chacun des K clusters, calculer le centroïde du cluster.
 - (b) Attribuez chaque observation au cluster dont le centroïde est le plus proche (où le plus proche est défini en utilisant la distance euclidienne par exemple).

Parce que l'algorithme K-means trouve une optimisation locale plutôt que globale, les résultats obtenus dépendront de l'affectation initiale (aléatoire) de chaque observation à l'étape 1 de l'algorithme. Pour cette raison, il est important d'exécuter l'algorithme plusieurs fois à partir de différentes configurations initiales aléatoires. Ensuite, en sélectionner la meilleure solution, c'est-à-dire

celle pour laquelle l'objectif est le plus petit.

Comme vu précédemment, pour effectuer un clustering K-means, il faut définir le nombre de clusters K dès le départ. Le problème de la sélection de K est loin d'être simple.

1.3.2 Clustering Hiérarchique

Un inconvénient potentiel de l'algorithme K-means est qu'il faut pré-spécifier le nombre de clusters K. Le clustering hiérarchique est une approche alternative qui ne nécessite pas un choix particulier de K. Le résultat du clustering est souvent traduit par une représentation arborescente attrayante des observations, appelée dendrogramme.

Le dendrogramme du clustering hiérarchique est obtenu via un algorithme extrêmement simple. Commençant par définir une sorte de mesure de dissimilarité entre chaque paire d'observations. Le plus souvent, la distance euclidienne est utilisée. L'algorithme se déroule de manière itérative. Partant du bas du dendrogramme, chacune des n observations est traitée comme son propre cluster. Les deux clusters qui se ressemblent le plus sont ensuite fusionnés pour qu'il y ait $n - 1$ clusters. Ensuite, les deux clusters qui se ressemblent le plus sont fusionnés à nouveau, de sorte qu'il en reste $n - 2$ clusters. L'algorithme procède de cette manière jusqu'à ce que toutes les observations appartiennent à un seul cluster et que le dendrogramme soit terminé.

L'algorithme de clustering hiérarchique est donné comme suit:

Algorithme Clustering Hiérarchique

1. Commencez par n observations et une mesure (telle que la distance) et traitez chaque observation comme un cluster.
2. Pour $i = n, n-1, \dots, 2$:
 - (a) Examinez toutes les dissemblances inter-cluster par paires parmi les i clusters et identifiez la paire de clusters qui sont les moins dissemblables (c'est-à-dire les plus similaires). Fusionnez ces deux clusters. La dissimilarité entre ces deux groupes indique la hauteur dans le dendrogramme

à laquelle la fusion doit être placée.

- (b) Calculez les nouvelles dissemblances inter-cluster par paire parmi les $i-1$ clusters restants.

Le concept de dissimilarité entre une paire d’observations doit être étendu à une paire de groupes d’observations. Cette extension est obtenue en développant la notion de lien, qui définit la dissimilarité entre deux groupes d’observations. Les quatre types de liens les plus courants - complet, moyen, unique et centroïde - sont brièvement décrits dans le tableau ci-dessous:

Linkage	Description
Complet	Différenciation intercluster maximale. Calculez toutes les disparités par paires entre les observations du cluster A et les observations du cluster B, et retenir la plus grande de ces différences.
Unique	Dissimilarité intercluster minimale. Calculez toutes les disparités par paire entre les observations du cluster A et les observations du cluster B et noter la plus petite de ces différences. Un couplage unique peut entraîner des clusters étendues dans lesquelles des observations uniques sont fusionnées une par une.
Moyen	Dissimilarité intercluster moyenne. Calculez toutes les disparités par paires entre les observations du cluster A et les observations du cluster B et notez la moyenne de ces différences.
Centroïde	La dissimilarité entre le centroïde du cluster A et le centroïde du cluster B. La liaison centroïde peut entraîner des inversions indésirables.

1.4 L’algorithme DCCA

Pour optimiser l’utilisation des ressources, et maximiser l’utilité des unités de traitement de base, l’association BBU-RRH doit prendre en considération les variations du trafic. En effet, la demande de trafic de données n’est pas uniformément distribuée sur les différentes régions et période du temps (voir figure 4). Donc, c’est important de regrouper des RRHs avec des schémas de trafic complémentaire afin que l’unité de traitement peut être pleinement utilisée à différentes périodes de temps. L’algorithme Distance-Constrained Complementarity-Aware

(DCCA) est une méthode proposée par [3] qui permet de trouver des schéma de clustering optimaux pour maximiser l'utilité de la capacité et réduire les coûts.




Figure 1.4: Volume de trafic

L'algorithme introduit une mesure de complémentarité entre les RRHs utilisée pour calculer la connectivité entre un RRH et un cluster. L'objectif de DCCA est d'avoir une connectivité entre un RRH 'r' et son cluster qui est supérieure à la connectivité entre 'r' et tout autre cluster.

$$\forall v \in C_k \text{ Con}(v, C) \geq \max \text{Con}(v, C_l), C_l \in P$$

Dans la méthode proposée, une étape de prédiction de trafic précède l'application de DCCA. Pour chaque RRH, un pattern de trafic est prédit pour une durée de temps future basé sur l'historique du trafic du RRH. Un model Multivariate Long Short-Term Memory (MuLSTM) est utilisé pour générer une matrice F. L'algorithme MuLSTM prend un F_i et retourne un F_{i+1} tel que F_i est une matrice de dimension $[Nt, Nr]$ avec, Nt: nombre de time slots et Nr: nombre des RRHs.

Ce modèle est utilisé pour prédire le trafic heure par heure pour le jour suivant. Le clustering des RRHs sera mis à jour dynamiquement selon ce trafic prédit. L'étape suivante est l'application de DCCA. Avant d'introduire l'algorithme, on va définir quelques mesures.

1.4.1 Définitions

1. **Distribution de peak hours :** Pour un cluster donné C, on récupère peak hours des RRHs du cluster, soit T. On calcule par la suite l'entropie

de shannon sur les probabilité d'avoir un peak-hour dans le cluster. Une grande valeur de l'entropie implique une grande incertitude ce qui veut dire une grande dispersion entre les peak hours dans le cluster.

$$H(C) = - \sum_{k=1}^K p_k \log p_k$$

Où $K=|T(C)|$ et p_k est la probabilité d'observer le peak hour correspondant dans l'ensemble $T(C)$.

2. **L'utilité de la capacité :** Le trafic aggréger des RRHs du cluster doit être proche à la capacité de la BBU du cluster sans la dépasser.

$$U(C) = \left(\frac{meanf(C)}{|B|} \right)^{\ln \frac{meanF(C)}{|B|}}$$

3. **Complémentarité :** $M(C) = U(C) * H(C)$

4. **Matrice de complémentarité :** Il faut prendre en considération la distance entre les RRHs pour que les délais de propagation entre BBU et RRH respectent les contraintes de qualité de service, et aussi pour permettre la communication entre RRHs. Donc on définit un τ tel que les RRHs qui sont séparés par une distance $> \tau$ ne sont pas regroupés ensemble. La matrice de complémentarité a la forme $[Nr, Nr]$ et associe à chaque couple (ri, rj) la valeur : $w(ri, rj) = M(ri, rj) * a_{ij}$ tel que $a_{ij} = \begin{cases} 1 & \text{si } dist(r_i, r_j) < \tau, \\ 0 & \text{sinon.} \end{cases}$

5. **Connectivité :** Elle représente la mesure de distance qui permet d'affecter un RRH à un cluster: $con(v, C) = \sum_{v' \in C} w_{vv'}$

Il faut prendre en considération de plus la distance entre le RRH et les autres clusters, on définit donc :

$$value(v, C) = con(v, C) * \log \left(\frac{\tau}{maxdist(v, v')} \right)$$

6. **Clusters adjacents :** $\mathbb{C}(v) = C | con(C, v) > 0, C \in \mathbb{P}$

L'algorithme DCCA peut être, donc, décrit comme suit :

Algorithme DCCA

1. Attribuez au hasard un numéro, de 1 à K, à chaque RRH. Ils servent comme clusters initiaux.

2. Itérez jusqu'à ce que les affectations de cluster cessent de changer, ou on atteint le nombre max d'itérations:
 - (a) Pour chaque RRH, on calcule les clusters adjacents : AC.
 - (b) Parmi les clusters de AC, on récupère celui qui a le $value(v,C)$ max, soit newC).
 - (c) Si newC est différent de l'ancien cluster de RRH, on reassigne RRH au nouveau cluster.
-

2. Conception

2.1 Analyse des données

Dans cette section on va analyser les données de géo-localisation et de trafic fournies par l'opérateur Orange pour les villes française: Paris, Nantes, Lille et Lyon.

2.1.1 Données Géographiques

Les données géographiques représentent les positions des RRHs sur un plan 2D (coordonnée x et y).

Analyse des données pour la ville Lille

- Nombre de RRHs est 1394 et le nombre de régions est de 88 RRHs (avec des RRHs à la même position).

- Cellules géographiques : le diagramme de Voronoi ci-dessous permet de délimiter les zones géographiques dont est responsable chaque RRH et ainsi calculer la superficie de la zone :




Figure 2.1: Diagramme de Voronoi pour Lille

- Pour chaque RRH on évalue le nombre RRHs à distance variante de celui-ci:
Exemple : Pour le RRH à la position (649540, 2626350) on obtient les graphes suivants avec un pas de 500 m:




Figure 2.2: Histogramme du nombre de RRHs par distance d'un point

2.1.2 Données de Trafic

Analyse des données pour la ville Lille

Les données de trafic renseignent pour chaque RRH le nombres de bytes up et bytes down pour des timeslot de 10min entre les mois de mars et juin 2019 ainsi que le maximum et minimum des bytes en up et down pour les RRHs tel que:

Min traffic up : 0.0 Max traffic up : 7249226387.374723

Min traffic down : 0.0 Max traffic down : 15828358767.955057

Les courbes suivantes représentent le trafic up et down pour un RRH donné:




Figure 2.3: Byte Up matin




Figure 2.4: Byte Up après 14h




Figure 2.5: Byte Down matin




Figure 2.6: Byte Down après 14h




Figure 2.7: Comparaison Byte Up et Byte Down matin




Figure 2.8: Comparaison Byte Up et Byte Down après 14h

On remarque bien que le trafic en down est beaucoup plus élevé qu'en up, et on peut facilement repérer les pics de trafic.

Les figures ci-dessous représente pour des périodes et jours différents le trafic RRH dans les régions du digramme de voronoi avec un code couleur.




Figure 2.9: Jour de semaine




Figure 2.10: Weekend




Figure 2.11: Jour de semaine




Figure 2.12: Weekend




Figure 2.13: Jour de semaine




Figure 2.14: Weekend

2.2 Application des algorithmes

Dans cette partie, on va implémenter les différents algorithmes. On commence par appliquer l'algorithme k-means et le clustering hiérarchique sur les données géographiques sans prendre en considération le trac. Ensuite, on applique une version de DCCA sur les données de trac et on évalue les résultats en variant les paramètres d'entrée.

2.2.1 Clustering sur les Données géographique

2.2.2 Clustering sur les Données du trafic

On applique DCCA sur le trac de la ville Lille avec des TimeSlot chaque une heure. Pour cela, on considère la moyenne du trac durant une heure. Pour des valeurs de τ , le seuil de distance, différentes on obtient les clusters suivants: